

大设施-zBiosynth使用文档

git地址: https://github.com/fuxuliu/zBioSynth/tree/dev_gary, 分支: dev_gary

项目结构

- zBioSynth
 - zbiosynth
 - core (训练引擎/logger)
 - engine.py
 -
 - data (不同类型数据的预处理脚本)
 - protein_sequence.py
 - nucleotide_sequence.py
 -
 - datasets (不同任务训练所需要的dataset class)
 - codon_optimized.py
 - kcat.py
 - protein_solubility.py
 -
 - layers ()
 - metrics (评估指标)
 - mlflow_pyfunc_models (打包mlflow model)
 - mlflow_py_models.py (mlflow model class封装)
 - mlflow_signatures.py (记录不同任务对应的mlflow model所需的输入与其输出)
 - models (模型定义)
 - esm2.py
 - codon_models.py

- rna_lm.py
-
- tasks (不同类型任务的定义)
 - codon_optimization.py
 - kcat_prediction.py
 - protein_solubility_prediction.py
 -
- transforms
- utils (工具)
 - comm.py
 - tools.py
- MLproject (mlflow project)
- run_single_pltform_mlflow.py (启动训练任务)
- submit_run.py (平台提交训练任务)
- zbiosynth.yml (所依赖的conda环境)
- setup.py (安装脚本)

已支持任务

```
task2config = {
    'enhancer_activity': './config/enhancer_activity/rnalmlflow.yaml',
    'protein_solubility': './config/soluprot/esm2_mlflow.yaml',
    'protein_mutation_ddg': './config/ddg/esm2_mlflow.yaml',    ## batchsize always 1? can > 1
    'enzyme_ecnumber': './config/enzyme_ecnumber/esm2_mlflow.yaml',    ## 8m maximum batch size 16
    'kcat': './config/kcat/lm_mlflow.yaml',
    'codon_optimization': './config/codon_optimized/codonlm_mlflow.yaml',
    'promoter': './config/promoter/rnalmlflow.yaml',
    'terminator': './config/terminator/rnalmlflow.yaml',
    'sgRNA_offtarget': './config/sgRNA_offtarget/rnalmlflow.yaml',
    'transcription_factor_binding_sites': './config/transcription_factor_binding_sites/rnalmlflow.yaml',
    'go': './config/go/esm2_mlflow.yaml',
    'go_bp': './config/go_single/BP_esm2_mlflow.yaml',
    'go_mf': './config/go_single/MF_esm2_mlflow.yaml',
    'go_cc': './config/go_single/CC_esm2_mlflow.yaml',
}
```

输入的task name必须是以上的task name，否则训练时找不到对应的task，task会自动找对应的config.yaml

- enhancer_activity -- dna序列的增强子活性预测 (回归)

- protein_solubility -- 蛋白质序列的溶解性二分类预测 (二分类)
- protein_mutaiton_ddg -- 蛋白质氨基酸突变的DDG预测 (回归)
- enzyme_ecnumber -- 酶EC number的预测 (多分类, 后面会改回多标签分类)
- kcat -- 酶转化效率Kcat预测 (回归)
- codon_optimization -- 密码子优化 (多分类)
- promoter -- 启动子二分类预测 (二分类)
- terminator -- 终止子二分类预测 (二分类)
- sgrna_offtarget -- sgrna 是否脱靶预测 (二分类)
- transcription_factor_binding_sites -- 转录因子结合位点预测 (二分类)
- go -- 蛋白质序列的go term预测 (3 x 多标签分类)
- go_bp -- 蛋白质序列BP 类别的go term预测 (多标签分类)
- go_mf -- 蛋白质序列MF 类别的go term预测 (多标签分类)
- go_cc -- 蛋白质序列 类别的go term预测 (多标签分类)

训练入口暴露的参数（目前）

```
def parse_args():
    parser = argparse.ArgumentParser()
    parser.add_argument("-t", "--task", help="specify task name", default='')
    parser.add_argument("--gpus", help="numbers of gpu are used", type=int, default=1)
    parser.add_argument("--learning_rate", help="learning rate", type=float, default=3.0e-4)
    parser.add_argument("--epochs", help="epochs", type=int, default=1)
    parser.add_argument("--batch_size", help="batch_size", type=int, default=32)
    parser.add_argument("--data_name", help="the name of data file", default='data.csv')
    parser.add_argument("--embedding_model", help="the name of embedding model", default='esm2_8m')
```

- --task 需要输入任务的名称
- --gpus 训练时需要使用的GPU数量, 若=0, 则使用cpu进行训练, 若>1, 则自动切换至多卡进行训练
- --learning_rate
- --epochs
- --batch_size
- --data_name 数据集csv文件的名称
- --embedding_model 预训练模型的名称
 - 预训练权重路径: /share/liufuxu/zBioSynth/resources/pretrained_weights, 目前支持以下预训练模型

- 如果是kcat这个任务，需要同时输入蛋白质和小分子的预训练模型名称，使用","隔开，并且蛋白质模型在前，如esm2_8m,smole-bert
- 蛋白质序列: "esm2_8m", "esm2_35m", "esm2_150m", "esm2_650m", "esm2_3B", "esm2_15B"
- 核酸序列: "rna1m_8m", "rna1m_35m", "rna1m_150m", "rna1m_650m"
- 密码子序列: "codon1m_8m", "codon1m_35m", "codon1m_650m"
- 小分子smile序列: "molt5-base", "molt5-small", "smole-bert"

使用案例(本地)

- 在本地跑的时候，数据集文件需要放在目录下的data目录下
- 安装zbiosynth，在目录下运行 `python setup.py install`
- git里面已经存放了一些任务所需的训练集，较大的没有上传，可在这个路径下获取 </share/liufuxu/zBioSynth/dataset/data>
- 每个task的config.yaml 里都有一个默认的 `model_path:/share/liufuxu/zBioSynth/resources/pretrained_weights`
本地跑的时候，自动在这个路径下寻找预训练模型。

密码子优化--codon_optimization

数据格式

csv with columns:

- **prot_seq**，蛋白质序列
- **dna_seq**，优化好的密码子序列/dna序列
- **split**，train/valid/test split

启动命令

```
1 python run_single_pltform_mlflow.py \
2 --task codon_optimization \
3 --learning_rate 3e-4 \
4 --epochs 5 \
5 --batch_size 4 \
6 --gpu 1 \
7 --data_name codon_optimized.csv \
8 --embedding_model codon1m_8m
```

mlflow model infer

```
tracking_uri: /user/liufuxu/project/zBioSynth/mlruns
artifact_uri: /user/liufuxu/project/zBioSynth/mlruns/7/0b11c99f95264a81b24ea25d44f06974/artifacts
run_id: 0b11c99f95264a81b24ea25d44f06974
ckpt_dir: /user/liufuxu/project/zBioSynth/mlruns/7/0b11c99f95264a81b24ea25d44f06974/artifacts/ckpts
```

替换上面的路径

```
1 pymodel_mlflow =
2 mlflow.pyfunc.load_model('/user/liufuxu/project/zBioSynth/mlruns/7/0b11c99
```

启动

```
1 python mlflow_infer_debug/codon_optimization.py
```

```
2023-10-09 11:35:06.633564: I tensorflow/core/util/util.cc:16  
s from different computation orders. To turn them off, set th  
100%|██████████  
  
dna_seq  
0 ATGAGCGATGTGGCGATTGTGAAAGAAGGCTGGCTGCATAAACGCCG...  
1 ATGGGCGCGCCGACCTTACC GCGCGCTGGCAGCGTTTCTGAAAG...  
2 ATGGCAGCATTAAGTGCGCGCGCGCGCGCGCAGAACAGGTC...  
3 ATGAGCGCGCGCAAATATGTGGATAGCGAAGGCCATCTGTATACCG...  
4 ATGGCGTGCAACTGCCAGCTGATGCAGGATACCCGCTGCTGAAAT ...  
5 ATGGAAGATTATACCAAAAATTGAAAAAATTGGCGAAGGCACCTATG...  
6 ATGGCGCGCGTGAAGAAGCCGCTGGAATTTATCGGAAACGCCGT ...  
7 ATGGGCGGCTGCGCAGCAGCGCTGCGCGCGTTTAGTGATAGCGAAG...  
8 ATGACCATGGAAGCGCGCGGAAAAACCAGCAGAGCGGCGATGCGG...  
9 ATGGCGAGCAGCAGCGCGCAGCAAAGCGGAATTTATTGTGGCGGCA...  
10 ATGGCGCGCGCTGCTGATGGCTTTAAACGCGCGGAACGCAAGCGG...  
11 ATGGCGAAACATAAAAAAAGTAAACAGCGCGGCGATGGCAACCCG...  
12 ATGCGCTTACTGCTGGCGTTACTGGGCGTGTTACTGAGCGTCCGG...  
13 ATGGTGAGCTATTGGGATACCGGCTGCTGTTGCGCGCTGTTAA...  
14 ATGAGCGGCGCGCGCGCACCAACAGCTTTGCGGAAAGCTGCAAAC...  
15 GAAGGCCCGGCGCTGGGCCGAGTATTGGCGCCATCTGCGCGCT...
```

sgRNA offtarget预测--sgrna_offtarget

数据格式

csv with columns:

- o **sgrna_seq**, sgrna序列
- o **dna_seq**, 靶点dna序列
- o **label**, 标签0/1
- o **split**

启动命令

```

1 python run_single_pltform_mlflow.py \
2 --task sgrna_offtarget \
3 --learning_rate 3e-4 \
4 --epochs 2 \
5 --batch_size 64 \
6 --gpus 1 \
7 --data_name sgrna_offtarget_v2.csv \
8 --embedding_model rna1m_8m

```

mlflow model infer

```

tracking_uri: /user/liufuxu/project/zBioSynth/mlruns
artifact_uri: /user/liufuxu/project/zBioSynth/mlruns/9/95849af82a0943a08da50aa810840563/artifacts
run_id: 95849af82a0943a08da50aa810840563
ckpt_dir: /user/liufuxu/project/zBioSynth/mlruns/9/95849af82a0943a08da50aa810840563/artifacts/ckpts

```

替换上面的路径

```

1 pmodel_mlflow =
2 mlflow.pyfunc.load_model('/user/liufuxu/project/zBioSynth/mlruns/9/9584

```

启动

```

1 python mlflow_infer_debug/sgrna_offtarget.py

```

```

(fairseq_tm) [liufuxu@gpu004 zBioSynth]$ python mlflow_infer_
2023-10-09 12:39:59.493924: I tensorflow/core/util/util.cc:169
s from different computation orders. To turn them off, set the
100%|
auc: 0.8924972837434504, bacc: 0.5375199264074454
(fairseq_tm) [liufuxu@gpu004 zBioSynth]$

```

Kcat预测--kcat

数据格式

csv with columns:

- **seq**, 蛋白质/酶序列
- **smile**, 小分子smile序列
- **kcat**, 标签

- **split**

启动命令

```
1 python run_single_pltform_mlflow.py \
2 --task kcat \
3 --learning_rate 3e-4 \
4 --epochs 5 \
5 --batch_size 8 \
6 --gpus 1 \
7 --data_name kcat.csv \
8 --embedding_model esm2_8m,smole-bert
```

mlflow model infer

```
tracking_uri: /user/liufuxu/project/zBioSynth/mlruns
artifact_uri: /user/liufuxu/project/zBioSynth/mlruns/5/ba6d12265be7486b9c189d33872dafb6/artifacts
run_id: ba6d12265be7486b9c189d33872dafb6
ckpt_dir: /user/liufuxu/project/zBioSynth/mlruns/5/ba6d12265be7486b9c189d33872dafb6/artifacts/ckpts
```

替换上面的路径

```
1 pymodel_mlflow =
2 mlflow.pyfunc.load_model('/user/liufuxu/project/zBioSynth/mlruns/5/ba6d122
3
```

启动

```
1 python mlflow_infer_debug/kcat.py
```

```
(ratrseq_tmp) [tuturuxu@gpu004 ZBtoSynth]$ python mltc
2023-10-09 14:34:32.312740: I tensorflow/core/util/ut
s from different computation orders. To turn them off
69%| ████████████████████████████████████████████████████
Token indices sequence length is longer than the spec
100%| ████████████████████████████████████████████████████
(0.35252390942252854, 1.8708584974180783e-50)
```

protein solubility预测--protein_solubility

数据格式

csv with columns:

- **seq**, 蛋白质序列
- **solubility**, 0/1标签
- **split**

启动命令

```
1 python run_single_pltform_mlflow.py \  
2 --task protein_solubility \  
3 --learning_rate 3e-4 \  
4 --epochs 5 \  
5 --batch_size 32 \  
6 --gpus 1 \  
7 --data_name soluprot.csv \  
8 --embedding_model esm2_8m
```

mlflow model infer

```
tracking_uri: /user/liufuxu/project/zBioSynth/mlruns  
artifact_uri: /user/liufuxu/project/zBioSynth/mlruns/2/3aa6f6a92d0b4c9d88130a92f6e2bdd6/artifacts  
run_id: 3aa6f6a92d0b4c9d88130a92f6e2bdd6  
ckpt_dir: /user/liufuxu/project/zBioSynth/mlruns/2/3aa6f6a92d0b4c9d88130a92f6e2bdd6/artifacts/ckpts
```

替换上面的路径

```
1 pymodel_mlflow =  
2 mlflow.pyfunc.load_model('/user/liufuxu/project/zBioSynth/mlruns/2/3aa6f6a92d0b4c9d88130a92f6e2bdd6/artifacts/ckpts/  
3
```

启动

```
1 python mlflow_infer_debug/soluprot.py
```


Enhancer activity预测--enhancer_activity

数据格式

csv with columns:

- **seq**, 核酸序列
- **activity**, 强度
- **split**

启动命令

```
1 python run_single_pltform_mlflow.py \  
2 --task enhancer_activity \  
3 --learning_rate 3e-4 \  
4 --epochs 5 \  
5 --batch_size 32 \  
6 --gpus 1 \  
7 --data_name rice_enhancer.csv \  
8 --embedding_model rna1m_8m
```

mlflow model infer

启动

```
1 python mlflow_infer_debug/soluprot.py
```

蛋白突变ddg预测--protein_mutaiton_ddg

数据格式

csv with columns:

- **wt_seq**, 野生型蛋白质序列
- **mut_seq**, 突变型蛋白质序列
- **position**, 突变位置，从1开始
- **ddg**, 标签
- **split**

启动命令

```
1 python run_single_pltform_mlflow.py \  
2 --task protein_mutation_ddg \  
3 --learning_rate 3e-4 \  
4 --epochs 5 \  
5 --batch_size 8 \  
6 --gpus 1 \  
7 --data_name ddg.csv \  
8 --embedding_model esm2_8m
```

mlflow model infer

启动

```
1 python mlflow_infer_debug/ddg.py
```

promoter/non-promoter预测--promoter

数据格式

csv with columns:

- **seq, 核酸序列**
- **label, 标签**
- **split**

启动命令

```
1 python run_single_pltform_mlflow.py \  
2 --task promoter \  
3 --learning_rate 3e-4 \  
4 --epochs 5 \  
5 --batch_size 32 \  
6 --gpus 1 \  
7 --data_name promoter.csv \  
8 --embedding_model rna_lm_8m
```

mlflow model infer

启动

```
1 python mlflow_infer_debug/promoter.py
```

使用案例(平台)

≡ / 算法服务 / 算法管理 / 新建算法

新增算法

* 算法名称:

zbiosynth-debug

描述:

内容描述

0 / 100

* 代码来源:

git仓库

* 代码仓库:

Github

Gitlab

Bitbucket

Gitee

* Git地址:

https://github.com/fuxuliu/zBioSynth.git

✓

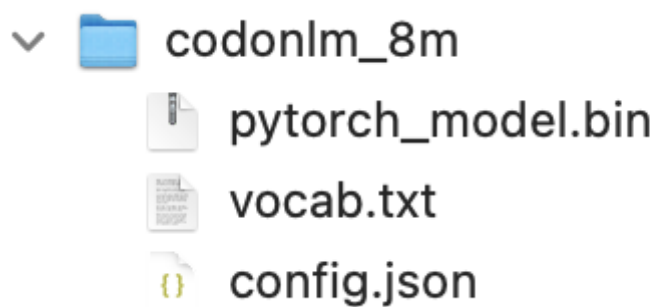
* revision:

dev_gary

✓

密码子优化

上传特征集，预训练模型，打包成codon_LM.zip, `zip -q -r codon_LM.zip codonlm_8m/`



预训练模型打包命名规则

路径: /share/liufuxu/zBioSynth/resources/pretrained_weights

蛋白质序列模型--prot_LM

```
130M      ./prot_LM/esm2_35m
2.5G      ./prot_LM/esm2_650m
57G       ./prot_LM/esm2_15B
7.9G      ./prot_LM/esmfold_v1
568M      ./prot_LM/esm2_150m
11G       ./prot_LM/prot_t5_xl
11G       ./prot_LM/esm2_3B
30M       ./prot_LM/esm2_8m
```

核酸序列模型--RNA_LM

```
2.5G      ./RNA_LM/rnaln_650m
30M       ./RNA_LM/rnaln_8m
568M      ./RNA_LM/rnaln_150m
130M      ./RNA_LM/rnaln_35m
```

密码子序列模型--codon_LM

```
512       ./codon_LM/codonln_150m
30M       ./codon_LM/codonln_8m
2.5G      ./codon_LM/codonln_650m
130M      ./codon_LM/codonln_35m
```

小分子序列模型--mol_LM

```
948M      ./mol_LM/mol_t5-base
297M      ./mol_LM/mol_t5-small
166M      ./mol_LM/smole-bert
```

新增特征集



* 特征集名称：

codonlm_8m

说明：

密码子序列预训练模型，8M模型参数量

特征集来源：

从标注任务选择

本地上传



点击上传文件按钮，或拖拽文件到这里

支持上传文件格式：zip

 codon_LM.zip

取消

确认

创建训练作业，记得选择特征集（预训练模型），由于平台暂不支持多个特征集的导入，数据集已传入git，暂时使用git里的数据集进行debug

基本信息

* 训练任务名称:

任务描述: 0 / 100

特征集选择:

* 算法来源: 我的算法 AutoML

* 超参:

task	=	codon_optimization
gpus	=	1
learning_rate	=	0.0003
epochs	=	5
batch_size	=	4
data_name	=	codon_optimized.csv
embedding_model	=	codonlm_8m

创建模型应用，构建模型

项目集

项目信息

项目概况

项目成员

项目配置

数据中心

数据集

数据处理

数据标注

特征库

算法服务

算法管理

模型服务

训练作业

模型应用

模型部署

模型仓库

创建模型

模型名称	最新版本
------	------

创建模型

* 模型名称: 13 / 25

* 版本:

描述:

* 选择算法:

* 选择训练作业:

取消

完成创建